Análisis de Enfermedades en Plantas Usando Procesamiento de Imágenes Digitales

Madi Sofía Colina Hernández

Juan Sebastián Sánchez Quimbaya

Universidad Militar Nueva Granada

Ingeniería en Multimedia

Javier Andrés Almeida Moreno

abril de 2026

Introducción

La agricultura moderna enfrenta múltiples desafíos relacionados con la productividad y la sanidad de los cultivos, siendo las enfermedades vegetales uno de los factores que más afectan el rendimiento agrícola a nivel mundial. En particular, el cultivo de tomate (*Solanum lycopersicum*) representa una de las especies hortícolas de mayor importancia económica, tanto por su alta demanda como por su amplia distribución global.

Dentro de las principales problemáticas que afectan este cultivo se encuentran las enfermedades foliares, las cuales pueden reducir significativamente la capacidad fotosintética de la planta y, en consecuencia, disminuir su producción. Entre estas enfermedades destaca el tizón temprano (*Early Blight*), causado por el hongo *Alternaria solani*, caracterizado por la aparición de manchas oscuras en las hojas.

En este contexto, la detección temprana de enfermedades se convierte en un factor clave para la toma de decisiones en el manejo agrícola. Sin embargo, los métodos tradicionales basados en inspección visual presentan limitaciones en términos de precisión, subjetividad y dificultad para identificar síntomas en etapas iniciales.

Ante esta problemática, el uso de técnicas de procesamiento digital de imágenes ha surgido como una alternativa prometedora, permitiendo analizar características visuales de las hojas de manera automatizada. Estas herramientas abren la posibilidad de desarrollar sistemas que contribuyan a una detección más objetiva, eficiente y reproducible de enfermedades en cultivos.

Planteamiento del Problema

A pesar de la importancia del cultivo de tomate, la detección del tizón temprano (*Early Blight*) continúa representando un desafío en los sistemas de producción agrícola. Actualmente, esta enfermedad es identificada principalmente mediante inspección visual en campo, lo que introduce problemas de subjetividad, baja precisión y dificultad para detectar síntomas en etapas tempranas.

Si bien en los últimos años se han desarrollado enfoques basados en procesamiento digital de imágenes y aprendizaje profundo para la detección automática de enfermedades, muchos de estos métodos requieren grandes volúmenes de datos, condiciones controladas de captura y altos recursos computacionales. Estas limitaciones dificultan su implementación en entornos reales, especialmente en contextos agrícolas con recursos limitados.

En consecuencia, existe la necesidad de desarrollar un sistema que permita la detección temprana, objetiva y robusta del tizón temprano en hojas de tomate, utilizando técnicas de procesamiento de imágenes que sean eficientes y aplicables en condiciones reales de captura.

Justificación

El desarrollo de métodos automatizados para la detección de enfermedades en cultivos constituye una herramienta fundamental dentro de la agricultura de precisión. Diversos estudios han demostrado que el uso de técnicas de visión por computador puede mejorar significativamente la detección temprana de enfermedades, reduciendo pérdidas y optimizando la producción agrícola.

Además, la implementación de soluciones basadas en procesamiento de imágenes permite disminuir la dependencia de expertos, facilitando su uso por agricultores con menor experiencia técnica.

En este sentido, un sistema automatizado puede apoyar el monitoreo del cultivo, mejorar la toma de decisiones y contribuir a la reducción de pérdidas productivas. Asimismo, este enfoque permite aplicar herramientas propias del procesamiento digital de imágenes en un problema agrícola real, integrando conocimientos teóricos y prácticos en el análisis de enfermedades foliares.

Estado del Arte

El uso de procesamiento digital de imágenes y aprendizaje automático ha crecido significativamente en la detección de enfermedades en plantas.

Diversos estudios han aplicado redes neuronales convolucionales (CNN) para la clasificación de enfermedades en hojas de tomate, alcanzando precisiones superiores al 97% en datasets como PlantVillage (Khan et al., 2024). En particular, modelos como ResNet, VGG y MobileNet han demostrado un alto rendimiento en la identificación de enfermedades como Early Blight, Late Blight y Bacterial Spot, alcanzando precisiones cercanas al 99% (Hossain et al., 2023).

No obstante, estos enfoques presentan limitaciones importantes. Los modelos de aprendizaje profundo requieren grandes volúmenes de datos etiquetados y alto poder computacional, además de depender en muchos casos de condiciones controladas de captura, lo que reduce su capacidad de generalización en entornos reales.

Por otro lado, métodos clásicos basados en procesamiento de imágenes —como segmentación por color, transformaciones de espacio RGB a HSV, filtrado y análisis de textura— han demostrado ser efectivos para identificar regiones afectadas en hojas (Chipuli & Luwemba, 2023). Estos métodos presentan ventajas en términos de eficiencia computacional y facilidad de implementación.

En comparación, los enfoques basados en aprendizaje profundo ofrecen alta precisión, pero presentan limitaciones en interpretabilidad y requerimientos computacionales. Por su parte, los métodos clásicos son más eficientes, aunque menos robustos frente a variaciones complejas, lo que evidencia la necesidad de desarrollar soluciones adaptadas a condiciones reales.

Investigaciones recientes han explorado modelos híbridos que combinan técnicas clásicas con aprendizaje automático, logrando mejorar la robustez frente a variaciones de iluminación y ruido (Umar et al., 2025).

Sin embargo, persisten desafíos importantes como la variabilidad en las condiciones de iluminación, la complejidad del fondo en imágenes reales y la necesidad de modelos eficientes que puedan implementarse en dispositivos de bajo costo.

A pesar de los avances en la detección automática de enfermedades en plantas, la mayoría de los estudios se centran en modelos de aprendizaje profundo entrenados en datasets bajo condiciones controladas, lo que limita su aplicabilidad en entornos reales de cultivo.

Asimismo, existe una menor exploración de enfoques basados en técnicas clásicas optimizadas que permitan una implementación eficiente, interpretable y accesible en contextos agrícolas reales.

Por tanto, se identifica un vacío en el desarrollo de sistemas que combinen eficiencia computacional, robustez ante condiciones reales y capacidad de detección temprana de enfermedades en hojas de tomate.

A partir del análisis del estado del arte, se propone el desarrollo de un sistema de detección de tizón temprano en hojas de tomate basado en técnicas de procesamiento digital de imágenes.

El sistema incluirá etapas de preprocesamiento para la normalización de iluminación, transformación de espacios de color (RGB a HSV o Lab), segmentación de regiones afectadas, aplicación de operaciones morfológicas y extracción de características relacionadas con color, textura y forma.

Este enfoque busca ofrecer una solución computacionalmente eficiente y robusta, orientada a su implementación en condiciones reales de cultivo, sin depender de modelos complejos de aprendizaje profundo.

Metodología

El desarrollo del presente proyecto se basa en la implementación de un sistema de detección del tizón temprano (*Early Blight*) en hojas de tomate mediante técnicas de procesamiento digital de imágenes. La metodología propuesta se compone de varias etapas, las cuales permiten transformar la imagen original en información útil para la identificación de la enfermedad.

El sistema propuesto se fundamenta en técnicas de procesamiento digital de imágenes en el dominio espacial, considerando la imagen como una función bidimensional $f(x, y)$, donde cada píxel representa un valor de intensidad.

1. Adquisición de datos

Para el desarrollo del sistema se utilizó el dataset **"Tomato Leaf Disease Dataset"** disponible en Mendeley Data, el cual contiene imágenes de hojas de tomate clasificadas según su estado de salud.

En particular, se seleccionaron las clases:

- Tomato Early Blight (hojas enfermas)
- Tomato Healthy (hojas sanas)

Las imágenes fueron capturadas en condiciones controladas, con fondo homogéneo y buena iluminación, lo que facilita la identificación de características visuales relevantes.

Las imágenes presentan variabilidad en resolución espacial, aunque en su mayoría se encuentran en formatos estándar (aproximadamente entre 256×256 y 512×512 píxeles), en formato RGB. La resolución espacial corresponde al número de píxeles utilizados para representar la imagen, lo cual influye directamente en la calidad del análisis.

2. Pre procesamiento, (Filtrado Espacial)

Durante la adquisición, las imágenes pueden contener ruido, el cual se modela como:

$$g\ (x\ ,y) = f(x\ ,y) + r(x\ ,y)$$

Donde $r(x\ ,y)$ representa el ruido.

Para reducir este efecto, se aplica un filtro Gaussiano, el cual suaviza la imagen mediante convolución:

$$G\ (x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

Este filtrado permite eliminar variaciones pequeñas de intensidad y mejorar la segmentación posterior.

3. Transformación de espacio de color

La imagen original en espacio RGB se transforma al espacio HSV, el cual permite separar:

- Tono (H)
- Saturación (S)
- Brillo (V)

Esto facilita la diferenciación entre tejido sano (verde) y tejido afectado (oscuro o marrón).

4. Segmentación

La segmentación se realiza mediante un proceso de umbralización, el cual permite separar regiones de interés:

$$f(x,y) = \begin{cases} 1, & si\ I\ (x\ ,y) > T \\ 0, & si\ I(x\ ,y) \leq T \end{cases}$$

Este proceso genera una imagen binaria donde las regiones afectadas pueden ser identificadas.

5. Operaciones Morfológicas

Posteriormente, se aplican operaciones de morfología matemática para mejorar la segmentación:

- Erosión: elimina píxeles aislados
- Dilatación: expande regiones relevantes

Estas operaciones permiten refinar la estructura de los objetos detectados, eliminando ruido y mejorando la forma de las regiones segmentadas.

6. Extracción de características

A partir de la imagen segmentada, se analizan propiedades como:

- Área de la región afectada
- Proporción de área enferma
- Distribución de intensidad

Estas características permiten cuantificar el grado de afectación de la hoja.

7. Clasificación

Finalmente, se establece un criterio de decisión basado en el porcentaje de área afectada:

- Si supera un umbral → hoja enferma
- En caso contrario → hoja sana

Este enfoque permite una clasificación eficiente sin necesidad de modelos complejos.

Resultados Parciales

Se implementó un sistema de segmentación basado en el espacio de color HSV y en el análisis de intensidad para la detección de regiones afectadas por tizón temprano en hojas de tomate.

En la etapa de segmentación, se aplicó un proceso de umbralización sobre la imagen transformada, permitiendo obtener una representación binaria de las regiones de interés, donde los píxeles correspondientes a posibles zonas afectadas fueron diferenciados del resto de la imagen.

Posteriormente, se aplicaron operaciones de morfología matemática, específicamente erosión, con el fin de eliminar ruido y refinar la forma de las regiones detectadas. Esto permitió mejorar la calidad de la segmentación, reduciendo la presencia de píxeles aislados.

A partir de la imagen segmentada, se realizó la extracción de características, calculando la proporción de área afectada respecto al total de la imagen. Esta métrica permitió cuantificar el grado de afectación de cada hoja.

Finalmente, se estableció un criterio de clasificación basado en un umbral sobre el porcentaje de área afectada, permitiendo diferenciar entre hojas sanas y enfermas.

Los resultados obtenidos evidencian que el método propuesto permite identificar de manera adecuada las zonas afectadas en hojas con presencia de la enfermedad, destacando regiones con cambios de color e intensidad característicos.

En el caso de hojas sanas, el sistema presenta una baja detección de regiones, aunque se observan algunos falsos positivos asociados a variaciones de iluminación y textura natural de la hoja.

En general, el enfoque demuestra ser efectivo para diferenciar entre hojas sanas y enfermas, cumpliendo con el objetivo de detección mediante técnicas de procesamiento digital de imágenes.

Resultados Parciales

Código implementando bibliotecas:

Referencias

Thalor M, Chavhan Y, Mate S. Performance Comparison of CNN Models for Tomato Disease Detection using Image-based data in Both Controlled and Real-world Conditions. Curr Agri Res 2025; 13(1). doi : http://dx.doi.org/10.12944/CARJ.13.1.11

Khan, M., Gulan, F., Arshad, M., Zaman, A., & Riaz, A. (2024b). Early and late blight disease identification in tomato plants using a neural network-based model to augmenting agricultural productivity. *Science Progress*, *107*(3), 368504241275371. https://doi.org/10.1177/00368504241275371

Hossain, M. I., Jahan, S., Asif, M. R. A., Samsuddoha, M., & Ahmed, K. (2023b). Detecting tomato leaf diseases by image processing through deep convolutional neural networks. *Smart Agricultural Technology*, *5*, 100301. https://doi.org/10.1016/j.atech.2023.100301

Chipuli, J. P., & Luwemba, G. W. (2023b). Tomato plant leaf disease detection using image recognition: A case study of MLALi in Morogoro region, Tanzania. *European Journal of Information Technologies and Computer Science*, *3*(4), 18–25. https://doi.org/10.24018/compute.2023.3.4.114

Umar, A. A., Kolajo, T., & Agbogun, J. B. (2025b). Systematic review of a convolutional neural network for detecting tomato leaf Disease. *Research Square*. https://doi.org/10.21203/rs.3.rs-7913477/v1

J, A. P. (2019). Data for: Identification of Plant Leaf Diseases Using a 9-layer Deep Convolutional Neural Network. *Data Archiving And Networked Services (DANS)*, *1*. https://doi.org/10.17632/tywbtsjrjv.1